Matemáticas Aplicadas para Ciencia de los Datos

Clase 3: Espacios vectoriales, Transformaciones lineales, valores y vectores propios, PCA

Diego Fonseca[1]

[1]Universidad EAFIT, Medellín, Colombia

Febrero 20, 2026

Espacios Vectoriales y Subespacios El universo donde viven nuestros datos

Tema: Espacios Vectoriales: Motivación

Hasta ahora, hemos tratado a los vectores y matrices como contenedores de datos. Pero para realizar operaciones de forma coherente (sumar, escalar, transformar), necesitamos un marco de referencia, un "universo" con reglas claras.

Un **espacio vectorial** es precisamente eso: un conjunto de objetos (nuestros datos) donde las operaciones de suma y multiplicación por escalar se comportan de la manera que esperamos.

¿Por qué es importante para la Ciencia de Datos?

- Formaliza las transformaciones de datos (ej. PCA, regresión).
- Nos permite entender conceptos como **redundancia** (dependencia lineal) y **componentes fundamentales** (bases).
- Es el fundamento sobre el que se construyen los algoritmos de optimización y machine learning.

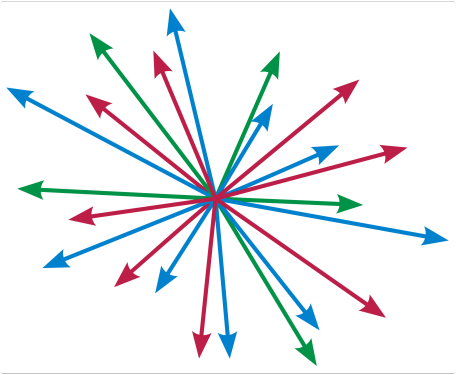

Definición (Espacio Vectorial Real)

Un conjunto no vacío V es un **espacio vectorial real** si está equipado con dos operaciones (suma de vectores y multiplicación por escalar) que satisfacen los siguientes diez axiomas para todo $\mathbf{u}, \mathbf{v}, \mathbf{w} \in V$ y escalares $\alpha, \beta \in \mathbb{R}$:

1. **Cerradura bajo la suma:** $\mathbf{u} + \mathbf{v} \in V$.
2. **Conmutatividad de la suma:** $\mathbf{u} + \mathbf{v} = \mathbf{v} + \mathbf{u}$.
3. **Asociatividad de la suma:** $(\mathbf{u} + \mathbf{v}) + \mathbf{w} = \mathbf{u} + (\mathbf{v} + \mathbf{w})$.
4. **Elemento neutro aditivo:** Existe un vector $\mathbf{0} \in V$ tal que $\mathbf{v} + \mathbf{0} = \mathbf{v}$.
5. **Inverso aditivo:** Para cada $\mathbf{v} \in V$, existe un $-\mathbf{v} \in V$ tal que $\mathbf{v} + (-\mathbf{v}) = \mathbf{0}$.
6. **Cerradura bajo la multiplicación escalar:** $\alpha\mathbf{v} \in V$.
7. **Distributividad (escalar sobre suma de vectores):** $\alpha(\mathbf{u} + \mathbf{v}) = \alpha\mathbf{u} + \alpha\mathbf{v}$.
8. **Distributividad (vector sobre suma de escalares):** $(\alpha + \beta)\mathbf{v} = \alpha\mathbf{v} + \beta\mathbf{v}$.
9. **Asociatividad de escalares:** $\alpha(\beta\mathbf{v}) = (\alpha\beta)\mathbf{v}$.
10. **Identidad multiplicativa:** $1\mathbf{v} = \mathbf{v}$.

Ejemplo (El Espacio Euclidiano $\mathbb{R}^n$)

El ejemplo más importante para nosotros. El conjunto de todos los vectores (o tuplas ordenadas) de n números reales.

$$\mathbb{R}^n = \{(x_1, x_2, \ldots, x_n) : x_i \in \mathbb{R}\}$$

Las operaciones usuales de suma y multiplicación por escalar componente a componente cumplen los 10 axiomas. Cada fila de nuestro 'DataFrame' puede ser un vector en $\mathbb{R}^n$.

Ejemplo (El Espacio de Matrices $M_{m\times n}$)

El conjunto de todas las matrices de tamaño $m \times n$ con entradas reales también forma un espacio vectorial con las operaciones matriciales estándar.

$$M_{m\times n} = \{\mathbf{A} : \mathbf{A} \text{ es una matriz de tamaño } m \times n\}$$

Una imagen en escala de grises de 1024×768 es un vector en el espacio vectorial $M_{1024\times 768}$.

Tema: Subespacios: Estructuras dentro de Estructuras

A menudo, los datos de interés no ocupan todo el espacio vectorial, sino un subconjunto más pequeño con la misma estructura.

Definición (Subespacio Vectorial)

Un subconjunto no vacío H de un espacio vectorial V es un **subespacio** de V si H es en sí mismo un espacio vectorial bajo las operaciones heredadas de V.

Criterio Simplificado para Subespacios

Para verificar si H es un subespacio de V, solo necesitamos comprobar tres cosas:

1. **Contiene el cero:** El vector nulo $\mathbf{0}$ de V está en H.
2. **Cerrado bajo la suma:** Si $\mathbf{u}, \mathbf{v} \in H$, entonces $\mathbf{u} + \mathbf{v} \in H$.
3. **Cerrado bajo multiplicación escalar:** Si $\mathbf{u} \in H$ y $\alpha \in \mathbb{R}$, entonces $\alpha\mathbf{u} \in H$.

Tema: Subespacios: Ejemplos Visuales en $\mathbb{R}^3$

No cualquier subconjunto de $\mathbb{R}^3$ es un subespacio.

Sí son subespacios:

- El origen $\{\mathbf{0}\}$. (Subespacio trivial)
- Cualquier **línea** que pase por el origen.
- Cualquier **plano** que pase por el origen.
- Todo el espacio $\mathbb{R}^3$.

No son subespacios:

- Una línea o plano que **no** pasa por el origen (falla la condición 1 y 3).
- Un cuadrante del plano xy (falla la condición 3, multiplicar por -1 nos saca del cuadrante).

Ejemplo (Intersección de Subespacios)

La intersección de dos subespacios (ej. dos planos distintos que pasan por el origen) es siempre un subespacio (en este caso, una línea que pasa por el origen).

$$H_1 = \{(x, y, z) : 2x - y - z = 0\}, \quad H_2 = \{(x, y, z) : x + 2y + 3z = 0\}$$

$$H_1 \cap H_2 = \{t(-1/5, -7/5, 1) : t \in \mathbb{R}\} \implies \text{Una línea por el origen}$$

Actividad (Análisis de Subconjuntos)

Determine si los siguientes subconjuntos H son subespacios del espacio vectorial V correspondiente. Justifique su respuesta.

1. $V = \mathbb{R}^2; \quad H = \{(x, y) \in \mathbb{R}^2 : y \geq 0\}$.
2. $V = \mathbb{R}^3; \quad H = \{(x, y, z) \in \mathbb{R}^3 : z = 0\}$ (el plano xy).
3. $V = M_{n\times n}; \quad H = \{\mathbf{D} \in M_{n\times n} : \mathbf{D} \text{ es una matriz diagonal}\}$.
4. $V = M_{2\times 2}; \quad H = \left\{\mathbf{A} \in M_{2\times 2} : \mathbf{A} = \begin{pmatrix} a & 1+a \\ 0 & 0 \end{pmatrix}\right\}$.
5. $V = M_{2\times 2}; \quad H = \left\{\mathbf{A} \in M_{2\times 2} : \mathbf{A} = \begin{pmatrix} a & b \\ -b & c \end{pmatrix}\right\}$.

Independencia Lineal, Bases y Dimensión

Encontrando los “ladrillos” fundamentales de los datos

Tema: Independencia Lineal: El Problema de la Redundancia

En un conjunto de datos, es común tener variables o características que son **redundantes**. Por ejemplo, si tenemos la temperatura en Celsius y en Fahrenheit, una de ellas no aporta información nueva.

El álgebra lineal nos da una herramienta precisa para detectar esta redundancia: la **independencia lineal**.

Definición (Combinación Lineal)

Un vector $\mathbf{v}$ es una **combinación lineal** de un conjunto de vectores $\{\mathbf{x}_1, \ldots, \mathbf{x}_k\}$ si se puede expresar como una suma ponderada de ellos:

$$\mathbf{v} = \lambda_1 \mathbf{x}_1 + \lambda_2 \mathbf{x}_2 + \cdots + \lambda_k \mathbf{x}_k$$

Idea Central

Si un vector en nuestro conjunto de datos puede ser escrito como una combinación lineal de otros, entonces es **linealmente dependiente** y no aporta información única.

Tema: Independencia Lineal: Definición Formal

Definición (Independencia Lineal)

Un conjunto de vectores $\{\mathbf{x}_1, \ldots, \mathbf{x}_k\}$ es **linealmente independiente** si la única forma de obtener el vector nulo como combinación lineal de ellos es con todos los pesos (escalares) iguales a cero:

$$\lambda_1\mathbf{x}_1 + \lambda_2\mathbf{x}_2 + \cdots + \lambda_k\mathbf{x}_k = \mathbf{0} \quad \Longleftrightarrow \quad \lambda_1 = \lambda_2 = \cdots = \lambda_k = 0$$

Si existe al menos un $\lambda_i \neq 0$ que satisface la ecuación, el conjunto es **linealmente dependiente**.

Ejemplo

Determinar si los vectores $\mathbf{x}_1 = \begin{pmatrix} 1 \\ -3 \\ 0 \end{pmatrix}, \mathbf{x}_2 = \begin{pmatrix} 3 \\ 0 \\ 4 \end{pmatrix}, \mathbf{x}_3 = \begin{pmatrix} 11 \\ -6 \\ 12 \end{pmatrix}$ son linealmente independientes.

Buscamos soluciones para $c_1\mathbf{x}_1 + c_2\mathbf{x}_2 + c_3\mathbf{x}_3 = \mathbf{0}$. Esto nos lleva al sistema de ecuaciones:

$$\begin{pmatrix} 1 & 3 & 11 \\ -3 & 0 & -6 \\ 0 & 4 & 12 \end{pmatrix} \begin{pmatrix} c_1 \\ c_2 \\ c_3 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}$$

Al resolver, encontramos una solución no trivial (ej. $c_1 = 2, c_2 = -3, c_3 = 1$). Por lo tanto, son **linealmente dependientes**. De hecho, $\mathbf{x}_3 = 2\mathbf{x}_1 + 3\mathbf{x}_2$.

Actividad (Independencia Lineal en Seguridad)

Contexto: Los códigos QR son matrices binarias. Podemos "aplanar" cada código QR de $N \times N$ en un vector de N^2 componentes. La independencia lineal es clave: si un código (que podría contener parte de una clave secreta) es una combinación lineal de otros, no es seguro.

Tarea: Se proporcionan 4 imágenes de códigos QR. Usando los primeros tres (QR1, QR2, QR3), determine si son linealmente independientes.

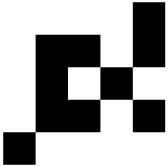

QR1

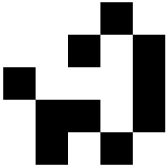

QR2

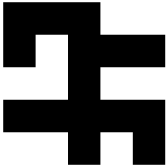

QR3

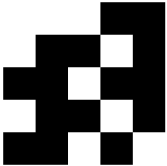

(Referencia)

Pasos sugeridos en Python:

1. Cargar las 3 imágenes y convertirlas a arrays de NumPy.
2. Aplanar cada matriz de imagen en un vector.
3. Construir una matriz donde cada columna es uno de estos vectores.
4. Analizar el rango o resolver el sistema homogéneo para determinar la dependencia.

Tema: Bases y Dimensión: Construyendo el Espacio

Si la independencia lineal nos ayuda a encontrar un conjunto de vectores sin redundancias, ¿cuál es el conjunto *mínimo* que necesitamos para "construir" todo nuestro espacio de datos?

Definición (Conjunto Generador "Span")

El **span** de un conjunto de vectores $\{\mathbf{x}_1, \ldots, \mathbf{x}_k\}$ es el conjunto de **todas las posibles combinaciones lineales** que se pueden formar con ellos. Es el subespacio "generado" por estos vectores.

Definición (Base)

Una **base** para un espacio vectorial V es un conjunto de vectores $\mathcal{B}$ que cumple dos condiciones:

1. $\mathcal{B}$ es **linealmente independiente** (no hay redundancia).
2. El **span de $\mathcal{B}$ es todo el espacio** V (genera todo).

Una base es el "diccionario" más eficiente para describir un espacio vectorial.

Proposición (Unicidad de la Representación)

Si $\mathcal{B}$ es una base de V, entonces todo vector $\mathbf{v} \in V$ se puede escribir de **forma única** como una combinación lineal de los vectores de $\mathcal{B}$. Las ponderaciones de esta combinación son las **coordenadas** de $\mathbf{v}$ en la base $\mathcal{B}$.

Definición (Dimensión)

Todas las bases de un espacio vectorial tienen el mismo número de vectores. Este número único se llama la **dimensión** del espacio vectorial, denotado $\dim(V)$.

Ejemplo

- La **base canónica** de $\mathbb{R}^3$ es $\{\mathbf{e}_1, \mathbf{e}_2, \mathbf{e}_3\} = \left\{ \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} \right\}$. Por lo tanto, $\dim(\mathbb{R}^3) = 3$.
- El espacio solución del sistema homogéneo $2x - y + 3z = 0$ tiene como base $\left\{ \begin{pmatrix} 1 \\ 2 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 3 \\ 1 \end{pmatrix} \right\}$. Es un plano en $\mathbb{R}^3$, y su dimensión es 2.

Actividad (Análisis de Datos Meteorológicos)

Contexto: Tenemos datos de sensores (Temperatura, Presión, Altitud). Aunque los medimos en la base canónica, quizás una base diferente, alineada con la física del problema, sea más reveladora.
Tarea: Vamos a transformar nuestros datos a una nueva base $\mathcal{B}$ y analizar los resultados.

$$\text{Base Canónica } \mathcal{E} = \{\mathbf{e}_1, \mathbf{e}_2, \mathbf{e}_3\} \xrightarrow{\text{Transformación}} \text{Nueva Base } \mathcal{B} = \{\mathbf{b}_1, \mathbf{b}_2, \mathbf{b}_3\}$$

Objetivos:

1. Transformar los datos de los sensores a la nueva base.
2. Comparar las distribuciones (histogramas) de las coordenadas en ambas bases.
3. Visualizar en 3D cómo se reorientan los datos respecto a los nuevos ejes.
4. Discutir: ¿Qué ventajas podría tener la nueva representación? ¿Alguna de las nuevas coordenadas parece menos importante (menor varianza)?

Tema: Cambio de Base: Actividad (Datos y Resultados)

Se utilizan los datos de `datos_sensoriales.csv` y se transforman a la nueva base dada por las columnas de la matriz **B**:

$$\mathbf{B} = \begin{pmatrix} 0{,}7 & 0{,}7 & 0 \\ 0{,}5 & -0{,}5 & 0{,}7 \\ 0{,}5 & -0{,}5 & -0{,}7 \end{pmatrix}$$

Datos Originales y Nueva Base

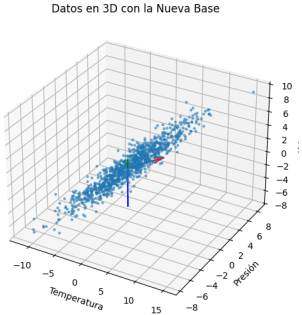

Comparación de Histogramas

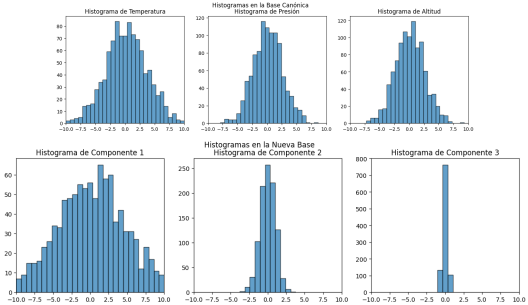

Análisis de Resultados: Al observar los histogramas de la nueva base, notamos que la Componente 3 tiene una varianza mucho menor que las otras dos. Esto sugiere que los datos se "aplanan" en esa dirección. En un escenario de reducción de dimensionalidad, esta podría ser una candidata a ser eliminada, simplificando el modelo con una pérdida mínima de información.

Actividad (Análisis de Datos Biomédicos)

Contexto: Repetimos el análisis con los datos de `datos_Biomedicos.csv` (Biome_size, Thyroid_size, Red_blood_cell_levels).

Nueva Base $\mathcal{B}'$:

$$\mathbf{B}' = \begin{pmatrix} 0{,}7 & 0{,}7 & 0 \\ 0{,}5 & -0{,}5 & 0{,}7 \\ -0{,}5 & 0{,}5 & 0{,}7 \end{pmatrix}$$

Tareas:

1. Transformar los datos biomédicos a la base $\mathcal{B}'$.
2. Generar y comparar los histogramas de las coordenadas.
3. Visualizar los datos en 3D con los nuevos ejes de la base.

Pregunta Clave: ¿Esta nueva base parece separar mejor la información? ¿Se observa algún efecto similar de reducción de varianza en alguna de las nuevas coordenadas como en el caso anterior?

Transformaciones Lineales, Rango y Nulidad

Transformaciones Lineales: Introducción: Motivación y Hoja de Ruta

En ciencia de datos, a menudo queremos transformar nuestros datos: cambiar su perspectiva, reducir su dimensionalidad, rotarlos o escalarlos. Las **transformaciones lineales** son el fundamento matemático para realizar estas operaciones de manera estructurada.

Hoja de Ruta de la Sesión:

1. **¿Qué es una Transformación Lineal?** Definición formal y propiedades.
2. **La Matriz de Transformación:** El puente entre el concepto abstracto y el cálculo computacional.
3. **Análisis de la Transformación:**
   - **Imagen y Rango:** ¿A dónde van a parar nuestros datos?
   - **Núcleo y Nulidad:** ¿Qué información se pierde o comprime?
4. **El Teorema de Rango-Nulidad:** La ley de conservación de la dimensión.
5. **Aplicaciones Prácticas:** Análisis de redes y conectividad.

Transformaciones Lineales: Definición Fundamental: ¿Qué es una Transformación Lineal?

Definición (Transformación lineal)

Una **transformación lineal** es una función $\Phi : V \to W$ entre dos espacios vectoriales V y W que "respeta" la estructura del espacio vectorial. Es decir, preserva las dos operaciones fundamentales: la suma de vectores y la multiplicación por un escalar.

Formalmente, para cualquier par de vectores $x, y \in V$ y cualquier escalar $\lambda \in \mathbb{R}$, se deben cumplir dos condiciones:

1. **Preservación de la Suma:** $\Phi(x + y) = \Phi(x) + \Phi(y)$.
2. **Preservación del Escalado:** $\Phi(\lambda x) = \lambda \Phi(x)$.

Observación

Estas dos condiciones se pueden combinar en una sola:

$$\Phi(\lambda x + \psi y) = \lambda \Phi(x) + \psi \Phi(y)$$

para cualquier $x, y \in V$ y $\lambda, \psi \in \mathbb{R}$. Esto significa que la transformación de una combinación lineal es la combinación lineal de las transformaciones.

Transformaciones Lineales: Propiedades: Inyectividad, Sobreyectividad, Isomorfismo

Al igual que con otras funciones, las transformaciones lineales pueden tener propiedades especiales:

- **Inyectiva (uno a uno):** Si entradas distintas siempre producen salidas distintas. Es decir, si $\Phi(x) = \Phi(y)$, entonces obligatoriamente $x = y$. Esto significa que no se pierde información.
- **Sobreyectiva (sobre):** Si todo elemento en el espacio de llegada W es la imagen de al menos un elemento del espacio de partida V. Es decir, $\mathrm{Im}(\Phi) = W$.
- **Biyectiva:** Si es tanto inyectiva como sobreyectiva. Una transformación biyectiva es invertible.

Definición (Isomorfismo)

Un **isomorfismo** es una transformación lineal que es biyectiva. Si existe un isomorfismo entre dos espacios vectoriales V y W, decimos que son **isomorfos**.

Teorema

Dos espacios vectoriales de dimensión finita son isomorfos si y solo si tienen la misma dimensión: $\dim(V) = \dim(W)$.

Observación

Esto es muy potente: ¡todos los espacios vectoriales de dimensión n son, en esencia, "el mismo" que $\mathbb{R}^n$!

Transformaciones Lineales: Representación Matricial: El Puente a la Computación

La idea más importante es que **toda transformación lineal** $\Phi : \mathbb{R}^n \to \mathbb{R}^m$ **puede ser representada por una matriz** $A \in \mathbb{R}^{m \times n}$. La acción de la transformación es simplemente una multiplicación matricial:

$$\Phi(\mathbf{x}) = \mathbf{A}\mathbf{x}$$

¿Cómo se construye esta matriz A?

1. Tomamos los vectores de la base canónica de $\mathbb{R}^n$: $\mathbf{e}_1, \mathbf{e}_2, \ldots, \mathbf{e}_n$.
2. Aplicamos la transformación a cada uno de ellos: $\Phi(\mathbf{e}_1), \Phi(\mathbf{e}_2), \ldots, \Phi(\mathbf{e}_n)$.
3. Colocamos los vectores resultantes como las **columnas** de la matriz **A**.

$$\mathbf{A} = \begin{bmatrix} | & | & & | \\ \Phi(\mathbf{e}_1) & \Phi(\mathbf{e}_2) & \ldots & \Phi(\mathbf{e}_n) \\ | & | & & | \end{bmatrix}$$

Esta matriz **A** se llama la **matriz de transformación**.

Transformaciones Lineales: Representación Matricial: Ejemplo de Construcción

Sea la transformación $T : \mathbb{R}^3 \to \mathbb{R}^4$ definida como:

$$T\begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} x - y \\ y + z \\ 2x - y - z \\ -x + y + 2z \end{bmatrix}$$

Aplicamos T a la base canónica de $\mathbb{R}^3$:

$$\mathbf{e}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \quad \mathbf{e}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{e}_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$$

- $T(\mathbf{e}_1) = T\begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 1 - 0 \\ 0 + 0 \\ 2(1) - 0 - 0 \\ -1 + 0 + 0 \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \\ 2 \\ -1 \end{bmatrix}$

  (1ra columna de A)

- $T(\mathbf{e}_2) = T\begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 - 1 \\ 1 + 0 \\ 0 - 1 - 0 \\ 0 + 1 + 0 \end{bmatrix} = \begin{bmatrix} -1 \\ 1 \\ -1 \\ 1 \end{bmatrix}$

  (2da columna de A)

- $T(\mathbf{e}_3) = T\begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} = \begin{bmatrix} 0 - 0 \\ 0 + 1 \\ 0 - 0 - 1 \\ 0 + 0 + 2 \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \\ -1 \\ 2 \end{bmatrix}$

  (3ra columna de A)

La matriz de transformación es:

$$\mathbf{A}_T = \begin{bmatrix} 1 & -1 & 0 \\ 0 & 1 & 1 \\ 2 & -1 & -1 \\ -1 & 1 & 2 \end{bmatrix}$$

Transformaciones Lineales: Análisis de la Transformación: Imagen y Núcleo

Una vez que tenemos la matriz de transformación **A**, podemos analizar sus propiedades fundamentales a través de dos subespacios clave:

Definición (Imagen (o Rango))

La **imagen** de Φ, denotada $\mathrm{Im}(\Phi)$, es el conjunto de todas las posibles salidas de la transformación.

$$\mathrm{Im}(\Phi) = \{\mathbf{w} \in W \mid \mathbf{w} = \Phi(\mathbf{v}) \text{ para algún } \mathbf{v} \in V\}$$

Corresponde al **espacio de columnas** de la matriz **A**.

Definición (Núcleo (o Espacio Nulo))

El **núcleo** de Φ, denotado $\ker(\Phi)$, es el conjunto de todos los vectores de entrada que son "aplastados" al vector cero en el espacio de salida.

$$\ker(\Phi) = \{\mathbf{v} \in V \mid \Phi(\mathbf{v}) = \mathbf{0}_W\}$$

Corresponde al **espacio nulo** de la matriz **A** (soluciones de $A\mathbf{x} = 0$).

La dimensión de la imagen se llama **rango**, $\rho(\Phi)$.

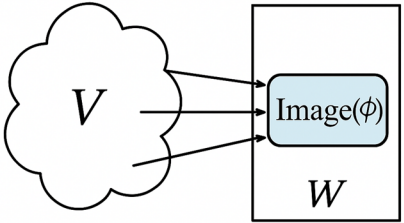

La dimensión del núcleo se llama **nulidad**, $\nu(\Phi)$.

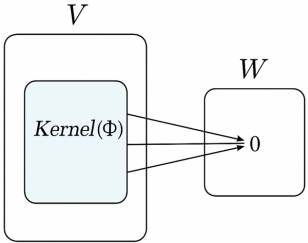

Transformaciones Lineales: El Teorema Fundamental: Rango-Nulidad

Existe una relación fundamental e inquebrantable entre la dimensión del espacio de entrada, el rango y la nulidad.

Teorema (Teorema de Rango-Nulidad)

Para cualquier transformación lineal $\Phi : V \to W$, donde V es de dimensión finita, se cumple que:

$$\dim(\mathrm{Im}(\Phi)) + \dim(\ker(\Phi)) = \dim(V)$$

O, de forma más compacta:

$$\text{rango}(\Phi) + \text{nulidad}(\Phi) = \text{dimensión del espacio de partida}$$

Interpretación en Ciencia de Datos:

- El **rango** nos dice la "dimensionalidad efectiva" de nuestros datos después de la transformación. Un rango bajo implica compresión o redundancia.
- La **nulidad** nos dice la "dimensionalidad de la información perdida" o cuántas dimensiones del espacio original se colapsaron en un solo punto (el origen).

Para una matriz $\mathbf{A} \in \mathbb{R}^{m \times n}$:

- **Espacio de Columnas (C_A):** El subespacio generado por las columnas de $\mathbf{A}$. Es la **imagen** de la transformación.
- **Espacio de Filas (R_A):** El subespacio generado por las filas de $\mathbf{A}$.
- **Espacio Nulo ($\mathbf{Nul}(A)$):** El conjunto de soluciones de $A\mathbf{x} = \mathbf{0}$. Es el **núcleo** de la transformación.

Teorema

Para cualquier matriz $\mathbf{A}$, la dimensión de su espacio de columnas es igual a la dimensión de su espacio de filas. Esta dimensión común es el **rango** de la matriz.

$$\dim(C_A) = \dim(R_A) = \text{rango}(A)$$

Observación

El rango de una matriz es invariante bajo operaciones elementales de fila, por lo que podemos calcularlo llevando la matriz a su forma escalonada (REF) y contando el número de pivotes.

Transformaciones Lineales: Invertibilidad: El Teorema de la Matriz Invertible

Para una matriz **cuadrada** $\mathbf{A} \in \mathbb{R}^{n \times n}$, muchas propiedades importantes son equivalentes. Si una es cierta, todas lo son.

Las siguientes afirmaciones son equivalentes:

1. A es una matriz **invertible**.
2. La transformación lineal asociada a A es un **isomorfismo**.
3. El sistema $A\mathbf{x} = \mathbf{0}$ tiene como **única solución** la trivial ($\mathbf{x} = \mathbf{0}$).
4. El **núcleo** de A es $\{\mathbf{0}\}$ (la nulidad es 0).
5. El **rango** de A es n ($\text{rango}(A) = n$).
6. Las columnas de A forman una **base** para $\mathbb{R}^n$.
7. Las filas de A forman una **base** para $\mathbb{R}^n$.
8. La forma escalonada reducida (RREF) de A es la matriz identidad I_n.
9. El determinante de A no es cero ($\det(A) \neq 0$).

Transformaciones Lineales: Ejercicio: Determinación de Rango y Base

Dada la matriz:

$$A = \begin{bmatrix} 1 & -1 & 3 \\ 2 & 0 & 4 \\ -1 & -3 & 1 \end{bmatrix}$$

Determine el **rango** y encuentre una **base** para su espacio de filas.
Solución: Aplicamos eliminación de Gauss para llevarla a su forma escalonada (REF).

$$\begin{bmatrix} 1 & -1 & 3 \\ 2 & 0 & 4 \\ -1 & -3 & 1 \end{bmatrix} \xrightarrow{R_2 \leftarrow R_2 - 2R_1} \begin{bmatrix} 1 & -1 & 3 \\ 0 & 2 & -2 \\ -1 & -3 & 1 \end{bmatrix} \xrightarrow{R_3 \leftarrow R_3 + R_1} \begin{bmatrix} 1 & -1 & 3 \\ 0 & 2 & -2 \\ 0 & -4 & 4 \end{bmatrix}$$

$$\xrightarrow{R_3 \leftarrow R_3 + 2R_2} \begin{bmatrix} 1 & -1 & 3 \\ 0 & 2 & -2 \\ 0 & 0 & 0 \end{bmatrix}$$

- La matriz en REF tiene **dos pivotes**. Por lo tanto, **rango(A) = 2**.
- Una base para el espacio de filas está formada por las filas no nulas de la matriz en REF: $\{(1, -1, 3), (0, 2, -2)\}$.

Aplicación: Análisis de Redes: Motivación

En sistemas complejos como redes de comunicación, transporte o sociales, la **conectividad** y la **redundancia** son clave para la robustez.

- Los **nodos** son los agentes (departamentos, intersecciones, personas).
- Las **aristas** son las conexiones (canales, calles, amistades).

Las rutas alternativas (o **ciclos**) en una red garantizan que si una conexión falla, la comunicación no se interrumpe. El álgebra lineal, específicamente el concepto de **núcleo (kernel)**, nos permite identificar y cuantificar estos ciclos de manera sistemática.

Aplicación: Actividad 3: Red de Comunicación Interna

Consideremos un grafo orientado con 4 departamentos (A, B, C, D) y 5 canales $(e_1, \ldots, e_5)$. El objetivo es analizar la redundancia de esta red.

$$
\begin{aligned}
&e_1 : A \to B, \quad e_2 : B \to C,\\
&e_3 : C \to D, \quad e_4 : D \to A,\\
&e_5 : C \to A.
\end{aligned}
$$

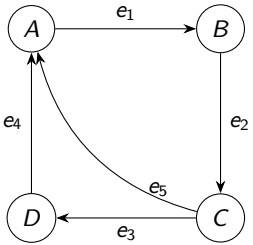

Aplicación: Actividad 3: Matriz de Incidencia y Kernel

Construimos la **matriz de incidencia**, donde las filas son los nodos (A, B, C, D) y las columnas los canales ($e_1, \ldots, e_5$). Usamos la convención: -1 para el origen, $+1$ para el destino.

$$\mathbf{A} = \begin{pmatrix} -1 & 0 & 0 & 1 & 1 \\ 1 & -1 & 0 & 0 & 0 \\ 0 & 1 & -1 & 0 & -1 \\ 0 & 0 & 1 & -1 & 0 \end{pmatrix}$$

El **kernel** de esta matriz ($\ker(A)$) contiene vectores que representan **ciclos** en el grafo. Un vector $\mathbf{x}$ en el kernel significa que $A\mathbf{x} = 0$, lo que implica que el "flujo" en la red está balanceado, es decir, todo lo que entra a un nodo, sale.

Observación

La dimensión del kernel (nulidad) nos da el número de ciclos independientes. Para un grafo conexo: Nulidad $=$ (número de aristas) $-$ (número de nodos) $+ 1$. Aquí, $\nu(A) = 5 - 4 + 1 = 2$. Esperamos encontrar una base con dos vectores para el kernel.

Aplicación: Actividad 3: Interpretando los Vectores del Kernel

Se puede demostrar (usando Gauss-Jordan) que una base para el kernel de **A** está dada por los vectores:

Ciclo 1: $A \to B \to C \to A$

- Usa e_1, e_2 y el inverso de e_5.
- Vector asociado:

$$\mathbf{x}_1 = \begin{pmatrix} 1 \\ 1 \\ 0 \\ 0 \\ -1 \end{pmatrix}$$

(Nota: El signo negativo en la componente de e_5 indica que se recorre en sentido contrario).

Ciclo 2: $A \to B \to C \to D \to A$

- Usa e_1, e_2, e_3, e_4.
- Vector asociado:

$$\mathbf{x}_2 = \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \\ 0 \end{pmatrix}$$

Conclusión de la Actividad: La nulidad $\nu(A) = 2$ nos confirma la existencia de dos rutas redundantes fundamentales. El análisis del kernel nos permite identificar exactamente cuáles son esas rutas, una información vital para la gestión de la red.

Aplicación: Actividad 4: Red de Transporte Urbano

Consideremos una red de transporte más compleja. El objetivo es el mismo: construir la matriz de incidencia, calcular su nulidad e interpretar los ciclos como rutas alternativas para el tráfico.

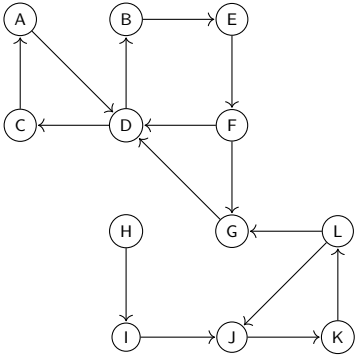

Actividad

1. Construya la matriz de incidencia asociada a este grafo.
2. Calcule la nulidad de la matriz. ¿Cuántos componentes conexos tiene la red? ¿Cuántos ciclos independientes hay en total?
3. Identifique un ciclo a simple vista y escriba el vector del kernel que lo representa.

Técnica Computacional: Matrices Particionadas

Para manejar matrices muy grandes, a veces es útil dividirlas en bloques o **submatrices**. Esto se conoce como **particionamiento de matrices**.
Por ejemplo, la matriz A se puede particionar como:

$$A = \begin{bmatrix} 2 & 3 & 4 \\ 5 & 6 & 1 \\ 0 & 2 & 3 \end{bmatrix} \quad \rightarrow \quad A = \left[\begin{array}{cc|c} 2 & 3 & 4 \\ 5 & 6 & 1 \\ \hline 0 & 2 & 3 \end{array}\right] = \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix}$$

donde $A_{11} = \left[\begin{smallmatrix} 2 & 3 \\ 5 & 6 \end{smallmatrix}\right]$, $A_{12} = \left[\begin{smallmatrix} 4 \\ 1 \end{smallmatrix}\right]$, etc.

Observación

Las operaciones como la suma y la multiplicación se pueden realizar por bloques, lo que puede ser computacionalmente más eficiente. Existen fórmulas para calcular la inversa de una matriz particionada, aunque son complejas y se usan en contextos específicos. Por ejemplo, para una matriz diagonal por bloques:

$$\text{Si } A = \begin{bmatrix} A_{11} & \mathbf{0} \\ \mathbf{0} & A_{22} \end{bmatrix}, \text{ entonces } A^{-1} = \begin{bmatrix} A_{11}^{-1} & \mathbf{0} \\ \mathbf{0} & A_{22}^{-1} \end{bmatrix}$$

Ejercicios Propuestos: Cálculo de Rango y Nulidad

Para las siguientes matrices, determine su **rango** y **nulidad**.

1. $\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$
2. $\begin{bmatrix} 1 & -1 & 2 \\ 3 & 1 & 0 \end{bmatrix}$
3. $\begin{bmatrix} -1 & 3 & 2 \\ 2 & -6 & -4 \end{bmatrix}$
4. $\begin{bmatrix} 1 & -1 & 2 \\ 3 & 1 & 4 \\ -1 & 0 & 4 \end{bmatrix}$
5. $\begin{bmatrix} 1 & -1 & 2 \\ 3 & 1 & 4 \\ 5 & -1 & 8 \end{bmatrix}$
6. $\begin{bmatrix} -1 & 2 & 1 \\ 2 & -4 & -2 \\ -3 & 6 & 3 \end{bmatrix}$
7. $\begin{bmatrix} 1 & -1 & 2 & 3 \\ 0 & 1 & 4 & 3 \\ 1 & 0 & 6 & 6 \end{bmatrix}$
8. $\begin{bmatrix} 2 & 3 \\ -1 & 1 \\ 4 & 7 \end{bmatrix}$

Conclusión: El Panorama Completo y Próximos Pasos

El Andamiaje Conceptual que Hemos Construido

En esta sesión, hemos viajado desde los fundamentos hasta las aplicaciones:

- **El Universo de los Datos:** Definimos los **espacios y subespacios vectoriales**, el marco formal donde viven nuestros datos.
- **Los Ladrillos Fundamentales:** Identificamos la **independencia lineal** para eliminar redundancia y definimos las **bases** como el diccionario más eficiente para describir los datos.
- **Las Medidas Clave:** Usamos el **determinante** para medir la escala del volumen (Varianza Generalizada) y el **rango** para medir la dimensionalidad efectiva.
- **Las Acciones sobre los Datos:** Aprendimos cómo las **transformaciones lineales** nos permiten manipular, rotar y cambiar la perspectiva de nuestros datos.

Vectores y Valores Propios

Descubriendo las direcciones fundamentales de los datos

Vectores y Valores Propios: Motivación: El Esqueleto de una Transformación

Imaginemos una transformación lineal representada por una matriz $\mathbf{A}$. Cuando aplicamos $\mathbf{A}$ a un vector $\mathbf{x}$, el resultado $\mathbf{Ax}$ generalmente cambia tanto su longitud como su dirección.

Pero, ¿existen algunas direcciones "especiales"?

- ¿Hay vectores cuya dirección **no cambia**, y solo son escalados (estirados o contraídos) por la transformación?
- Estas direcciones, si existen, forman el "esqueleto" o los "ejes principales" de la transformación. Nos revelan su comportamiento más fundamental.

Idea Central

Los **vectores propios** son esas direcciones invariantes, y los **valores propios** son los factores de escala asociados. En ciencia de datos, esto es la base para encontrar las direcciones de **máxima varianza** en nuestros datos (PCA).

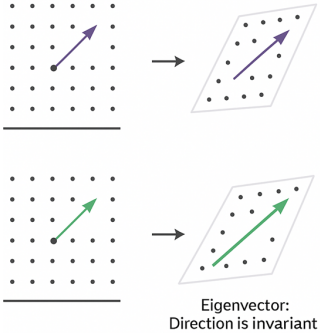

Vectores y Valores Propios: Definición Formal

Definición (Valor y Vector Propio)

Sea $\mathbf{A}$ una matriz cuadrada de $n \times n$. Un escalar λ (que puede ser real o complejo) se llama un **valor propio** (o autovalor) de $\mathbf{A}$ si existe un vector **no nulo** $\mathbf{v} \in \mathbb{C}^n$ tal que:

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$$

Cualquier vector no nulo $\mathbf{v}$ que satisfaga esta ecuación se denomina **vector propio** (o autovector) de $\mathbf{A}$ asociado al valor propio λ.

Interpretación Geométrica:

- La acción de la matriz $\mathbf{A}$ sobre su vector propio $\mathbf{v}$ es simplemente **escalar** $\mathbf{v}$ por el factor λ.
- Si $\lambda > 0$, la dirección de $\mathbf{v}$ se mantiene.
- Si $\lambda < 0$, la dirección de $\mathbf{v}$ se invierte.
- Si $\lambda = 1$, el vector $\mathbf{v}$ es un **punto fijo** de la transformación.
- Si $\lambda = 0$, el vector $\mathbf{v}$ es "aplastado" al origen; pertenece al **núcleo** de $\mathbf{A}$.

Vectores y Valores Propios: El Método de Cálculo: La Ecuación Característica

¿Cómo encontramos estos pares $(\lambda, \mathbf{v})$? Reordenamos la ecuación fundamental:

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$$

$$\mathbf{A}\mathbf{v} - \lambda\mathbf{v} = \mathbf{0}$$

$$\mathbf{A}\mathbf{v} - \lambda\mathbf{I}\mathbf{v} = \mathbf{0}$$

$$(\mathbf{A} - \lambda\mathbf{I})\mathbf{v} = \mathbf{0}$$

Esta es una ecuación de un sistema homogéneo. Queremos encontrar una solución **no trivial** ($\mathbf{v} \neq \mathbf{0}$). Esto solo ocurre si la matriz $(\mathbf{A} - \lambda\mathbf{I})$ es **singular** (no invertible).

La Ecuación Característica

Una matriz es singular si y solo si su determinante es cero. Por lo tanto, los valores propios λ de $\mathbf{A}$ son las raíces de la **ecuación característica**:

$$\det(\mathbf{A} - \lambda\mathbf{I}) = 0$$

Esta ecuación da como resultado un polinomio en λ de grado n, llamado **polinomio característico**.

Vectores y Valores Propios: Conexiones Profundas: Determinante y Traza

El polinomio característico revela dos propiedades muy importantes que conectan los valores propios con el determinante y la traza.
Si $\lambda_1, \lambda_2, \ldots, \lambda_n$ son los valores propios de una matriz $\mathbf{A}$ (incluyendo multiplicidades):

- **El Determinante es el Producto de los Valores Propios:**

$$\det(\mathbf{A}) = \prod_{i=1}^{n} \lambda_i = \lambda_1 \cdot \lambda_2 \cdot \cdots \cdot \lambda_n$$

  Interpretación: El cambio de volumen total es el producto de los factores de escala en las direcciones principales.

- **La Traza es la Suma de los Valores Propios:**

$$\mathrm{tr}(\mathbf{A}) = \sum_{i=1}^{n} a_{ii} = \sum_{i=1}^{n} \lambda_i = \lambda_1 + \lambda_2 + \cdots + \lambda_n$$

  Interpretación en datos: La Variación Total (suma de varianzas) se preserva como la suma de las varianzas en las direcciones de los componentes principales.

Observación

Estas propiedades son extremadamente útiles para verificar cálculos y para la teoría detrás de muchos algoritmos.

Vectores y Valores Propios: Propiedades Clave

- **Espacio Propio:** Para un valor propio λ, el conjunto de todos sus vectores propios correspondientes, junto con el vector nulo, forma un subespacio vectorial llamado **espacio propio** de λ. Es el núcleo de $(\mathbf{A} - \lambda\mathbf{I})$.
- **Independencia Lineal:** Los vectores propios correspondientes a *distintos* valores propios son siempre **linealmente independientes**.
- **Matrices Simétricas:** Si $\mathbf{A}$ es una matriz simétrica ($\mathbf{A} = \mathbf{A}^\top$), sus valores propios son siempre **reales** y sus vectores propios correspondientes a distintos valores propios son **ortogonales**. ¡Esto es crucial para PCA!
- **Matriz Transpuesta:** $\mathbf{A}$ y su transpuesta $\mathbf{A}^\top$ tienen los mismos valores propios.

Ejemplo Detallado: Paso 1: Planteamiento

Ejemplo (Cálculo Completo)

Encontremos los valores y vectores propios de la matriz:

$$\mathbf{A} = \begin{bmatrix} 4 & 2 \\ 3 & 3 \end{bmatrix}$$

Paso 1: Formular la ecuación característica $\det(\mathbf{A} - \lambda \mathbf{I}) = 0$.

$$\mathbf{A} - \lambda \mathbf{I} = \begin{bmatrix} 4 & 2 \\ 3 & 3 \end{bmatrix} - \lambda \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 4-\lambda & 2 \\ 3 & 3-\lambda \end{bmatrix}$$

La ecuación a resolver es:

$$\det \begin{pmatrix} 4-\lambda & 2 \\ 3 & 3-\lambda \end{pmatrix} = 0$$

Ejemplo Detallado: Paso 2: Encontrar Valores Propios

Paso 2: Resolver la ecuación característica para encontrar los λ.

$$\det \begin{pmatrix} 4-\lambda & 2 \\ 3 & 3-\lambda \end{pmatrix} = (4-\lambda)(3-\lambda) - (2)(3) = 0$$

Desarrollamos el polinomio:

$$12 - 4\lambda - 3\lambda + \lambda^2 - 6 = 0$$

$$\lambda^2 - 7\lambda + 6 = 0$$

Factorizamos la ecuación cuadrática:

$$(\lambda - 6)(\lambda - 1) = 0$$

Los **valores propios** son las raíces de esta ecuación:

$$\boxed{\lambda_1 = 6, \quad \lambda_2 = 1}$$

Ejemplo Detallado: Paso 3: Encontrar Vectores Propios

Paso 3: Para cada valor propio, encontrar su espacio propio resolviendo $(\mathbf{A} - \lambda \mathbf{I})\mathbf{v} = \mathbf{0}$.

Para $\lambda_1 = 6$:

$$(\mathbf{A} - 6\mathbf{I})\mathbf{v} = \mathbf{0}$$

$$\begin{pmatrix} 4-6 & 2 \\ 3 & 3-6 \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$\begin{pmatrix} -2 & 2 \\ 3 & -3 \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

Ambas ecuaciones se reducen a $-v_1 + v_2 = 0$, es decir, $\mathbf{v_1} = \mathbf{v_2}$.

Un vector propio representativo es $\mathbf{v}_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$. El espacio propio es $\text{gen}\left\{\begin{pmatrix} 1 \\ 1 \end{pmatrix}\right\}$.

Para $\lambda_2 = 1$:

$$(\mathbf{A} - 1\mathbf{I})\mathbf{v} = \mathbf{0}$$

$$\begin{pmatrix} 4-1 & 2 \\ 3 & 3-1 \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$\begin{pmatrix} 3 & 2 \\ 3 & 2 \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

Ambas ecuaciones se reducen a $3v_1 + 2v_2 = 0$. Una solución es tomar $v_1 = 2, v_2 = -3$. Un vector propio representativo es $\mathbf{v}_2 = \begin{pmatrix} 2 \\ -3 \end{pmatrix}$. El espacio propio es $\text{gen}\left\{\begin{pmatrix} 2 \\ -3 \end{pmatrix}\right\}$.

Ejemplo Detallado: Paso 4: Conclusión y Verificación

Resumen de Resultados:

- Para $\lambda_1 = 6$, un vector propio es $\mathbf{v}_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$.
- Para $\lambda_2 = 1$, un vector propio es $\mathbf{v}_2 = \begin{pmatrix} 2 \\ -3 \end{pmatrix}$.

Verificación con Propiedades:

- Suma de valores propios: $\lambda_1 + \lambda_2 = 6 + 1 = 7$.
- Traza de la matriz: $\text{tr}(\mathbf{A}) = 4 + 3 = 7$. (*Coincide!*)
- Producto de valores propios: $\lambda_1 \cdot \lambda_2 = 6 \cdot 1 = 6$.
- Determinante de la matriz: $\det(\mathbf{A}) = (4)(3) - (2)(3) = 12 - 6 = 6$. (*Coincide!*)

Visualización Geométrica: La transformación $\mathbf{A}$ estira cualquier vector en la dirección de $\begin{pmatrix} 1 \\ 1 \end{pmatrix}$ por un factor de 6, y deja a cualquier vector en la dirección de $\begin{pmatrix} 2 \\ -3 \end{pmatrix}$ sin cambio de longitud.

Actividad (Práctica de Cálculo)

Calcule los valores y vectores propios de las siguientes matrices.

1. $\begin{bmatrix} -2 & -2 \\ -5 & 1 \end{bmatrix}$
2. $\begin{bmatrix} -12 & 7 \\ -7 & 2 \end{bmatrix}$
3. $\begin{bmatrix} 2 & -1 \\ 5 & -2 \end{bmatrix}$
4. $\begin{bmatrix} -3 & 0 \\ 0 & -3 \end{bmatrix}$ *(¿Qué nota?)*
5. $\begin{bmatrix} -3 & 2 \\ 0 & -3 \end{bmatrix}$
6. $\begin{bmatrix} 3 & 2 \\ -5 & 1 \end{bmatrix}$
7. $\begin{bmatrix} 1 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 1 \end{bmatrix}$ *(Simétrica)*
8. $\begin{bmatrix} 1 & 1 & -2 \\ -1 & 2 & 1 \\ 0 & 1 & -1 \end{bmatrix}$
9. $\begin{bmatrix} 5 & 4 & 2 \\ 4 & 5 & 2 \\ 2 & 2 & 2 \end{bmatrix}$ *(Simétrica)*

Aplicación: Análisis de Componentes Principales (PCA): La Idea Central

El Problema: Tenemos datos en alta dimensión. Muchas variables pueden estar correlacionadas (ser redundantes) y es difícil visualizar la estructura de los datos.

La Solución (PCA): Encontrar un nuevo sistema de coordenadas (una nueva base) para nuestros datos tal que:

1. Los nuevos ejes (llamados **Componentes Principales**) apunten en las direcciones de **máxima varianza** de los datos.
2. Cada eje sea **ortogonal** a los demás (no hay redundancia entre componentes).
3. La mayoría de la información (varianza) de los datos originales se concentre en los primeros pocos ejes.

La Conexión Mágica

¡Los **vectores propios** de la **matriz de covarianza** de los datos son exactamente estas direcciones de máxima varianza (los Componentes Principales)!
¡Los **valores propios** correspondientes nos dicen **cuánta varianza** captura cada componente!

Aplicación: PCA: El Algoritmo

Dado un conjunto de datos $\mathbf{X} \in \mathbb{R}^{n \times d}$ (n observaciones, d variables).

1. **Centrar los Datos:** Para cada columna (variable), restar su media. $\mathbf{X}_c = \mathbf{X} - \text{media}(\mathbf{X})$.
2. **Calcular la Matriz de Covarianza:**
$$\Sigma = \frac{1}{n-1}\mathbf{X}_c^\top \mathbf{X}_c \quad (\text{una matriz de } d \times d)$$
3. **Realizar la Descomposición Propia de Σ:** Encontrar todos los pares de valores y vectores propios $(\lambda_i, \mathbf{v}_i)$ de la matriz de covarianza Σ.
4. **Ordenar Componentes:** Ordenar los valores propios de mayor a menor: $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_d$. Reordenar los vectores propios correspondientemente.
5. **Seleccionar Componentes:** Escoger las primeras k componentes (vectores propios $\mathbf{v}_1, \ldots, \mathbf{v}_k$) según un criterio (ej. explican el 95 % de la varianza). Formar la matriz $\mathbf{V}_k = [\mathbf{v}_1 | \ldots | \mathbf{v}_k]$.
6. **Proyectar los Datos (Cambio de Base):** Los datos en la nueva base de dimensionalidad reducida son:
$$\mathbf{Y} = \mathbf{X}_c \mathbf{V}_k \quad (\text{una matriz de } n \times k)$$

Aplicación: PCA: Criterios de Selección de k

¿Cuántas componentes principales (k) debemos retener? No hay una única respuesta, pero sí criterios comunes:

- **Varianza Explicada Acumulada:** El criterio más popular. La proporción de varianza explicada por las primeras k componentes es:
$$\frac{\sum_{i=1}^{k} \lambda_i}{\sum_{j=1}^{d} \lambda_j} = \frac{\sum_{i=1}^{k} \lambda_i}{\mathrm{tr}(\Sigma)}$$
Elegimos la k más pequeña que supere un umbral deseado (ej. 80 %, 90 %, 95 %).
- **Gráfico de Sedimentos (Scree Plot):** Se grafica cada valor propio λ_i en orden descendente. Buscamos un "codo" (elbow) en el gráfico, un punto donde la curva se aplana. Las componentes antes del codo son las más significativas.
- **Criterio de Kaiser (para datos estandarizados):** Si los datos han sido estandarizados (media 0, varianza 1), se retienen solo las componentes con valores propios $\lambda_i > 1$.

Aplicación: PCA: Manejo de Multiplicidad

¿Qué pasa si un valor propio λ tiene multiplicidad $m > 1$?
Esto significa que existe un **espacio propio** de dimensión m asociado a λ. Cualquier vector en este subespacio es un vector propio.

Implicaciones para PCA:

- Indica una **simetría** en la dispersión de los datos. Por ejemplo, si los datos forman una nube circular en 2D, $\lambda_1 = \lambda_2$ y cualquier par de vectores ortogonales puede ser la base.
- **No es un problema.** El procedimiento estándar es encontrar una *base ortonormal* para ese espacio propio de dimensión m. Estos m vectores formarán m componentes principales, cada una capturando la misma cantidad de varianza λ.
- La varianza total explicada por ese bloque de componentes, $m \times \lambda$, es la misma sin importar qué base ortonormal elijamos para el subespacio.

Observación

En la práctica, debido al ruido numérico, es raro encontrar valores propios exactamente iguales. Lo que sí se puede ver es un grupo de valores propios muy cercanos, lo que también sugiere una simetría aproximada en los datos.

Aplicación: PCA: Ejercicio Teórico 1

Enunciado: Para un conjunto de datos bidimensional, se realiza PCA y se encuentra que la matriz de covarianza es:

$$\Sigma = \begin{pmatrix} 29 & -6 \\ -6 & 21 \end{pmatrix}$$

1. Calcule los valores propios de Σ.
2. Calcule los vectores propios normalizados (unitarios). El primer componente principal es el vector propio asociado al mayor valor propio.
3. ¿Qué porcentaje de la varianza total es explicado por el primer componente principal?

Enunciado 2: Suponga que para un problema en $\mathbb{R}^3$, la matriz de covarianza Σ tiene valores propios $\lambda_1 = 4{,}5$, $\lambda_2 = 1{,}2$, $\lambda_3 = 0{,}3$.

1. ¿Cuál es la varianza total de los datos?
2. Calcule la proporción de varianza explicada por cada componente.
3. Si necesita retener al menos el 90 % de la varianza, ¿cuántas componentes debe seleccionar?

Actividad Práctica: PCA desde Cero datos_personas.csv

Actividad (Análisis de Componentes Principales)

Contexto y Objetivo: Vamos a aplicar PCA desde cero sobre 5 variables del archivo `datos_personas.csv` para entender su estructura de varianza y reducir su dimensionalidad.

Instrucciones en Python:

1. Cargar los datos y seleccionar las variables numéricas: 'Ingresos_Anuales', 'Deudas_Anuales', 'Seguro_Accidente', 'Valor_Carro', 'Gasto_Gasolina'.
2. **Estandarizar los datos** (media 0, desviación estándar 1). Esto es crucial porque las variables tienen escalas muy diferentes.
3. Calcular la **matriz de covarianza** de los datos estandarizados (que es igual a la matriz de correlación de los datos originales).
4. Calcular los **valores y vectores propios** de esta matriz.
5. **Analizar los resultados:**
   - Generar el **gráfico de sedimentos (Scree Plot)**.
   - Calcular y graficar la **varianza explicada acumulada**.
   - Crear un **heatmap** de correlación entre las variables originales y las nuevas componentes principales.
6. Concluir cuántas componentes son necesarias para capturar, por ejemplo, el 80 % de la información.

Actividad Práctica: PCA desde Cero Resultados (1)

Varianza Explicada por Componente

- **Scree Plot:** Muestra la magnitud de cada valor propio. Vemos un claro "codo" después de las dos primeras componentes.
- **Varianza Acumulada:** El gráfico muestra qué porcentaje de la varianza total se captura al añadir cada componente.

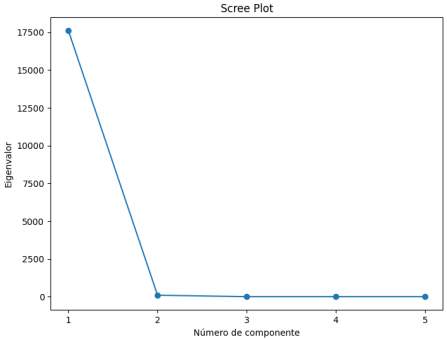

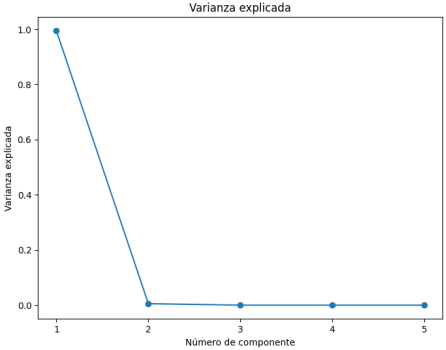

Observación

Con solo 2 componentes principales, ya explicamos más del 70 % de la varianza total contenida en las 5 variables originales. Para superar el 80 %, necesitaríamos 3 componentes.

Actividad Práctica: PCA desde Cero Resultados (2)

Correlación entre Variables Originales y Componentes Principales

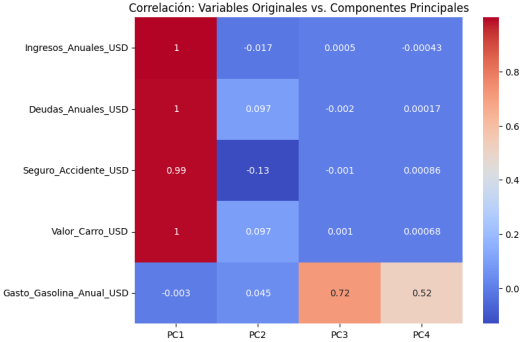

Interpretación:

- **Comp. 1 (PC1):** Tiene altas correlaciones (positivas o negativas) con casi todas las variables. Representa una especie de "índice general de estatus financiero".
- **Comp. 2 (PC2):** Contrasta fuertemente 'Seguro_Accidente' con 'Deudas_Anuales' y 'Valor_Carro'. Podría representar un eje de "aversión al riesgo vs. apalancamiento".

Observación

Este análisis nos permite dar un significado intuitivo a las nuevas dimensiones abstractas que hemos encontrado.

Actividad Práctica: Compresión de Imágenes: Usando PCA

Actividad (PCA para Compresión)

Contexto: Una imagen en escala de grises es una matriz. PCA puede reducir su "dimensionalidad" al encontrar las direcciones (vectores propios) que mejor capturan la estructura de la imagen.

Procedimiento:

1. Cargar `imagen_gris.png` como una matriz $\mathbf{X}$.
2. Aplicar PCA a esta matriz para obtener los valores y vectores propios.
3. **Comprimir:** Proyectar la imagen sobre las primeras k componentes principales: $\mathbf{Y} = \mathbf{X}_c \mathbf{V}_k$.
4. **Almacenar:** Para la compresión, guardamos la matriz proyectada $\mathbf{Y}$, la matriz de componentes $\mathbf{V}_k$, y la media.
5. **Reconstruir:** Recuperar una aproximación de la imagen original: $\mathbf{X}_{\text{reconst}} = \mathbf{Y}\mathbf{V}_k^\top + \text{media}(\mathbf{X})$.

Tareas:

1. Visualizar la imagen reconstruida para diferentes valores de k (ej. $k = 1, 5, 20, 50, 100$).
2. Comparar la calidad visual y el nivel de compresión logrado.

Conclusiones Finales de la sección

Ideas Fundamentales de la Sección

- Los **valores y vectores propios** revelan la estructura intrínseca de una transformación lineal, mostrando las direcciones que permanecen invariantes en orientación.
- El cálculo de estos pares $(\lambda, \mathbf{v})$ se realiza a través de la **ecuación característica**, $\det(\mathbf{A} - \lambda\mathbf{I}) = 0$.
- El determinante y la traza de una matriz están íntimamente ligados a sus valores propios (producto y suma, respectivamente).

La Aplicación Estrella: PCA

- El **Análisis de Componentes Principales (PCA)** utiliza la descomposición propia de la **matriz de covarianza** para encontrar un nuevo sistema de coordenadas alineado con la máxima varianza de los datos.
- Es una de las técnicas más potentes y fundamentales para la **reducción de dimensionalidad**, la **visualización de datos** y la **eliminación de colinealidad**.

Entender los valores propios es entender cómo simplificar y encontrar la esencia de datos complejos.

Fuentes principales:

- **Marc Peter Deisenroth, A. Aldo Faisal, y Cheng Soon Ong** (2020) *Mathematics for Machine Learning*. Cambridge University Press. Disponible en `https://mml-book.github.io/`
- **Daniel Peña** (2002) *Análisis de datos multivariantes.* McGraw-Hill
- **Avrim Blum, John Hopcroft y Ravindran Kannan** (2018) *Foundations of Data Science*. Cambridge University Press Disponible en `https://www.cs.cornell.edu/jeh/book.pdf`